

Universidade Federal de Sergipe

Departamento de Computação

Tópicos Avançados em Engenharia de Software e Sistemas de Informação I

Atividade Avaliativa 1

Curadoria de Datasets e Inferência Básica com LLMs

Equipe 3: Domínio Jurídico

Reinan Gabriel dos Santos Souza — Matrícula: 202521000190

Fernanda Mirely Barbosa Souza — Matrícula: 202611011405

Éricles dos Santos Cunha — Matrícula: 202611011094

Victor Leonardo Mascarenhas Soares Horta — Matrícula: 202511001890

Abril de 2026

Vídeo demonstrativo:

<https://youtu.be/1QMsZ2w0lt0>

Sumário

1	Introdução	3
2	Contribuições individuais	3
2.1	Reinan Gabriel dos Santos Souza	3
2.1.1	Escolha e justificativa dos modelos	3
2.1.2	Resultados da avaliação exata	4
2.1.3	Resultados da avaliação cruzada	5
2.1.4	Resultados da avaliação com modelo juiz	8
2.2	Fernanda Mirely Barbosa Souza	10
2.2.1	Escolha e justificativa dos modelos	10
2.2.2	Resultados das questões objetivas	11
2.2.3	Consistência entre modelos nas questões abertas	12
2.2.4	Desempenho nas questões abertas	13
2.2.5	Síntese	14
2.3	Éricles dos Santos Cunha	14
2.3.1	Escolha e justificativa dos modelos	15
2.3.2	Resultados das questões objetivas	15
2.3.3	Consistência entre modelos nas questões abertas	16
2.3.4	Desempenho nas questões abertas	16
2.3.5	Síntese e classificação final	18
2.3.6	Resultados da avaliação cruzada	19
2.3.7	Resultados da avaliação com modelo juiz	20
2.4	Victor Leonardo Mascarenhas Soares Horta	21
2.4.1	Escolha e justificativa dos modelos	21
2.4.2	Resultados da avaliação exata	22
2.4.3	Resultados das Questões Objetivas (J2)	22
2.4.4	Desempenho nas Questões Abertas (J1)	23
2.4.5	Consistência entre Modelos nas Questões Abertas	24
2.4.6	Síntese e Classificação Final	24
2.4.7	Resultados da Avaliação Cruzada	24
3	Referências	25

1 Introdução

Este documento apresenta os resultados da atividade avaliativa 1 da disciplina Tópicos Avançados em Engenharia de Software e Sistemas de Informação I, ministrada na Universidade Federal de Sergipe (UFS), semestre 2026.1.

A atividade consiste na curadoria de datasets jurídicos e na realização de inferência básica utilizando Modelos de Linguagem (LLMs), com foco em questões do Exame da OAB (Ordem dos Advogados do Brasil). Embora a execução das tarefas de curadoria e análise seja individual, a entrega e consolidação dos resultados são feitas em equipe.

O presente relatório documenta as contribuições da **Equipe 3 (Jurídica)**. Cada membro da equipe ficou responsável por um lote específico de questões, e suas contribuições individuais são detalhadas na Seção 2.

2 Contribuições individuais

Esta seção detalha as contribuições de cada membro da equipe na execução da atividade.

2.1 Reinan Gabriel dos Santos Souza

Toda a implementação do pipeline, desde a curadoria das questões até a geração dos gráficos de avaliação, está disponível no repositório público no GitHub¹. O repositório segue a abordagem *Docs-as-Code*, com documentação técnica versionada. A partir dele é possível acessar a documentação web e navegar pelos artefatos para visualizar os resultados obtidos.

2.1.1 Escolha e justificativa dos modelos

A seleção dos modelos foi condicionada pelo hardware disponível, especificamente uma GPU NVIDIA GeForce GTX 1050 com apenas 4 GB de VRAM dedicada. Essa restrição limitou a escolha a LLMs compactos, com até aproximadamente 3 bilhões de parâmetros, em versões quantizadas que não ultrapassassem 2 GB de armazenamento.

Foram selecionados três modelos de organizações distintas, todos executados localmente via Ollama, a saber, o **Gemma 2 2B**, o **Llama 3.2 3B** e o **Qwen 2.5 3B**. A escolha priorizou três critérios, compatibilidade com o hardware disponível, diversidade de desenvolvedores para evitar viés arquitetural e suporte ao idioma português, requisito essencial para o domínio jurídico brasileiro.

¹https://github.com/reinanhs/Topicos_Avancados_2026_1_Equipe_JUD_3_atividade1

2.1.2 Resultados da avaliação exata

A Tabela 1 apresenta o desempenho dos três modelos nas 122 questões objetivas do lote atribuído, avaliados por meio de Acurácia, Precisão, Recall e F1-Score. O **gemma2:2b** obteve a maior acurácia (0,4344), seguido pelo **qwen2.5:3b** (0,4180) e **llama3.2:3b** (0,3607). Nenhum modelo ultrapassou 50%, resultado esperado considerando o tamanho reduzido dos modelos e a complexidade inerente às questões da OAB.

Tabela 1: Avaliação exata do desempenho dos modelos em questões objetivas

Modelo	Acurácia	Precisão	Recall	F1
gemma2:2b	0,4344	0,4322	0,4448	0,4101
llama3.2:3b	0,3607	0,3519	0,3563	0,3473
qwen2.5:3b	0,4180	0,3609	0,3405	0,3337

A Figura 1 permite visualizar essa comparação de forma mais direta. Observa-se que o **gemma2:2b** mantém valores ligeiramente superiores em todas as métricas, enquanto o **llama3.2:3b** fica consistentemente abaixo dos demais. A Figura 2 complementa essa análise com um gráfico radar, no qual o **gemma2:2b** apresenta o polígono mais simétrico e amplo, indicando o perfil mais equilibrado entre os três modelos.




Figura 1: Métricas de avaliação exata na comparação entre modelos




Figura 2: Desempenho geral dos modelos em gráfico radar

2.1.3 Resultados da avaliação cruzada

Para as 12 questões dissertativas, que não possuem gabarito oficial, a avaliação foi conduzida de duas formas: comparação entre as respostas dos próprios modelos e comparação com a guideline de referência fornecida pelo dataset. A Tabela 2 apresenta as métricas de similaridade entre os pares de modelos, enquanto a Tabela 3 mostra a aderência de cada modelo à guideline.

Tabela 2: Avaliação cruzada de similaridade entre pares de modelos

Par de modelos	BLEU	ROUGE-1	ROUGE-2	ROUGE-L	BERTScore F1
gemma2:2b vs llama3.2:3b	0,1205	0,4575	0,1789	0,2459	0,7319
gemma2:2b vs qwen2.5:3b	0,1011	0,4741	0,1734	0,2256	0,7394
llama3.2:3b vs qwen2.5:3b	0,1025	0,4473	0,1664	0,2320	0,7323

Tabela 3: Aderência dos modelos à guideline de referência.

Modelo vs Guideline	BLEU	ROUGE-1	ROUGE-2	ROUGE-L	BERTScore F1
gemma2:2b vs guideline	0,0216	0,1534	0,0585	0,1126	0,6569
llama3.2:3b vs guideline	0,0215	0,1600	0,0571	0,1113	0,6632
qwen2.5:3b vs guideline	0,0172	0,1260	0,0447	0,0910	0,6513

Os modelos apresentam concordância semântica razoável entre si, com BERTScore F1 acima de 0,73 em todos os pares, apesar da baixa sobreposição lexical ($BLEU \approx 0,10-0,12$). Já a similaridade com a guideline é consideravelmente menor (BERTScore F1 em

torno de 0,65), indicando que, embora os modelos concordem entre si, suas respostas se distanciam do padrão de referência esperado.

A Figura 3 ilustra essa diferença por meio de um heatmap de similaridade semântica. As células entre modelos apresentam tons mais intensos (maior similaridade), enquanto as comparações com a guideline aparecem em tons mais claros.




Figura 3: Heatmap de similaridade semântica entre modelos e guideline.

A Figura 4 detalha todas as métricas de similaridade entre os pares de modelos. O BERTScore F1 é consistentemente a métrica mais elevada, enquanto o BLEU permanece baixo, resultado esperado, pois o BERTScore captura a semântica contextual, ao passo que o BLEU depende da correspondência exata de n-gramas.




Figura 4: Comparação entre pares de modelos com métricas de similaridade

A Figura 5 apresenta a aderência de cada modelo à guideline. Os valores baixos de BLEU e ROUGE confirmam que os modelos não reproduzem literalmente o texto de referência, embora o BERTScore em torno de 0,65 sugira certa proximidade semântica.




Figura 5: Aderência dos modelos à guideline de referência.

A Figura 6 complementa essa análise com gráficos radar individuais. Todos os modelos apresentam um padrão semelhante: alta concentração no eixo do BERTScore F1 e valores baixos nas demais métricas, reforçando a diferença entre similaridade lexical e semântica.




Figura 6: Perfil de métricas por modelo em relação à guideline.

A Figura 7 desagrega o BERTScore F1 por turn. O Turn 1 tende a apresentar scores ligeiramente superiores ao Turn 2 em praticamente todos os pares, o que pode indicar que a segunda parte das questões exige respostas mais específicas, nas quais os modelos divergem mais.




Figura 7: Distribuição do BERTScore F1 por turno para todos os pares

2.1.4 Resultados da avaliação com modelo juiz

Além das métricas automáticas de similaridade, um modelo juiz (GPT-4o-mini) foi utilizado para avaliar qualitativamente as respostas dissertativas. A Tabela 4 apresenta os scores médios atribuídos a cada modelo.

Tabela 4: Score médio atribuído pelo modelo juiz GPT-4o-mini.

Modelo	Score Médio
qwen2.5:3b	0,189
llama3.2:3b	0,139
gemma2:2b	0,120

A Figura 8 ilustra essa classificação. Os valores baixos de todos os modelos refletem a dificuldade geral de LLMs compactos diante de questões jurídicas dissertativas que exigem fundamentação técnica aprofundada.




Figura 8: Score médio por modelo.

A Figura 9 ilustra que a desagregação por *turn* evidencia comportamentos distintos entre os modelos. O **llama3.2:3b** apresenta um aumento expressivo do Turn 1 (0,083) para o Turn 2 (0,205), enquanto o **qwen2.5:3b** exibe comportamento oposto, com redução no segundo *turn*. Esse resultado sugere diferenças na capacidade de aprofundamento das respostas entre os modelos.




Figura 9: Score do juiz por modelo e turn.

O heatmap da Figura 10 detalha os scores por questão individual. Questões de direito administrativo obtiveram melhor desempenho geral, enquanto questões de direito do trabalho foram as mais difíceis para todos os modelos. Nota-se também que nenhum modelo domina todas as questões, evidenciando comportamentos complementares entre eles.




Figura 10: Scores do juiz por questão e modelo.

2.2 Fernanda Mirely Barbosa Souza

Questões atribuídas: J1: 141–152 | J2: 1477–1599

A estruturação integral do fluxo de processamento e predição — englobando as fases de seleção de exames da OAB, tratamento de dados, processamento por meio de Modelos de Linguagem de Grande Escala (LLMs) e aferição de indicadores de desempenho — está acessível em repositório público no GitHub ². O projeto adota a metodologia Docs-as-Code, convergindo a documentação técnica e o código-fonte em um sistema de controle de versionamento unificado.

2.2.1 Escolha e justificativa dos modelos

Os experimentos foram executados em ambiente local com um processador AMD Ryzen 3 3200G, 32 GB de RAM e GPU integrada Radeon Vega 8, sem VRAM dedicada. Essa configuração impôs que toda a inferência fosse realizada predominantemente em CPU e memória principal, por meio do Ollama. Apesar da limitação, o pipeline completo — inferência, avaliação e curadoria — foi concluído com êxito.

Foram selecionados os mesmos três modelos compactos utilizados pelos demais membros da equipe: **Llama 3.2 (3B)**, **Gemma 2 (2B)** e **Qwen 2.5 (3B)**. A escolha priorizou a diversidade de desenvolvedores (*Meta*, *Google* e *Alibaba*), o suporte nativo ao português — requisito essencial para questões da OAB — e a disponibilidade no ecossistema Ollama. O modelo **Llama 3.2 3B** foi empregado adicionalmente como modelo juiz na avaliação por rubrica e na avaliação comparativa das questões abertas. Nesse contexto, o conjunto dos três modelos escolhidos estabelece uma estrutura metodológica sólida para a realização das análises:

Llama 3.2 3B é um modelo de linguagem de grande escala desenvolvido pela *Meta*, otimizado para execução eficiente em dispositivos locais através de uma arquitetura densa de 3 bilhões de parâmetros. Ele utiliza técnicas de destilação de conhecimento de modelos maiores para manter capacidades avançadas de raciocínio e compreensão textual em um formato compacto.

Gemma 2:2b representa uma família de modelos abertos e leves da *Google*, construídos a partir da mesma tecnologia e infraestrutura utilizadas na criação da linha *Gemini*. Com 2 bilhões de parâmetros, este modelo prioriza a segurança e o desempenho por parâmetro, sendo projetado especificamente para tarefas de processamento de linguagem natural que exigem baixa latência e integração em fluxos de trabalho de pesquisa.

Qwen 2.5 3B é um modelo autoregressivo desenvolvido pela *Alibaba Cloud*, pertencente

²https://github.com/safira1344/Topicos_Avancados_2026_1_Equipe_JUD_3_atividade1

à série Qwen que se destaca pelo treinamento em vastos conjuntos de dados multilingues e de código. Esta versão de 3 bilhões de parâmetros apresenta melhorias significativas em capacidades lógicas, matemáticas e de seguimento de instruções complexas, demonstrando competitividade superior em *benchmarks* de modelos de pequeno porte.

2.2.2 Resultados das questões objetivas

A Tabela 5 apresenta o desempenho dos modelos nas 122 questões de múltipla escolha do lote atribuído. O **qwen2.5:3b** obteve a maior acurácia (50,41%), sendo o único a ultrapassar 50%, seguido pelo **gemma2:2b** (41,46%) e pelo **llama3.2:3b** (39,84%). O qwen2.5:3b também liderou em Precisão (0,5118), Recall (0,4991) e F1-Score (0,4818), com margem expressiva sobre os demais.

Tabela 5: Métricas de classificação dos modelos nas questões objetivas

Modelo	Acurácia	Precisão	Recall	F1
qwen2.5:3b	0,5041	0,5118	0,4991	0,4818
gemma2:2b	0,4146	0,4089	0,4127	0,4020
llama3.2:3b	0,3984	0,3971	0,3987	0,3860

Esse resultado é consistente com o lote de Éricles, no qual o *qwen2.5:3b* também liderou as questões objetivas com acurácia idêntica (50,41%). A convergência entre lotes distintos sugere que a superioridade do *Qwen 2.5* em questões de múltipla escolha do domínio jurídico não é pontual, mas reflete uma capacidade mais robusta de seleção de alternativas nesse formato.

Na Figura 11 exibe melhor os resultados, no qual, indicam que o modelo **Qwen 2.5:3b** obteve o desempenho superior, com acurácia de aproximadamente 50%. Os modelos **Gemma 2:2b** e **Llama 3.2:3b** apresentaram resultados inferiores e equivalentes entre si, situando-se na faixa de 40%. A uniformidade entre as métricas de Precisão, Recall e F1-Score sugere estabilidade na capacidade de classificação, apesar da complexidade inerente ao dataset jurídico.




Figura 11: Métricas de avaliação exata na comparação entre modelos

2.2.3 Consistência entre modelos nas questões abertas

Para as 12 questões dissertativas, foram calculadas métricas de similaridade entre cada par de modelos. A Tabela 6 apresenta os resultados.

Tabela 6: Métricas de similaridade entre pares de modelos nas questões abertas

Par de modelos	BLEU	ROUGE-1	ROUGE-2	ROUGE-L	BERTScore F1
llama3.2:3b vs gemma2:2b	0,1143	0,4987	0,2077	0,2574	0,7525
llama3.2:3b vs qwen2.5:3b	0,1361	0,5037	0,2147	0,2519	0,7571
gemma2:2b vs qwen2.5:3b	0,1239	0,5149	0,1962	0,2458	0,7506

Os três pares mantêm BERTScore F1 acima de 0,75, indicando que os modelos convergem semanticamente apesar de utilizarem vocabulários distintos. O BLEU permanece entre 0,11 e 0,14 e o ROUGE-L não ultrapassa 0,26, confirmando baixa sobreposição lexical — comportamento esperado em respostas jurídicas abertas. Esses valores de BERTScore entre 0,75 e 0,76, reforça que a estabilidade da concordância semântica entre os modelos independentemente do subconjunto de questões avaliado.

A Figura 12 apresenta a análise comparativa cross-model para questões abertas, utilizando as métricas BLEU, ROUGE-1, ROUGE-L e BERTScore F1 para mensurar a similaridade entre as respostas geradas pelos pares de modelos Llama 3.2:3b, Gemma 2:2b e Qwen 2.5:3b.




Figura 12: Comparação entre pares de modelos com métricas de similaridade

Os resultados demonstram uma alta convergência semântica entre todos os pares testados, com o BERTScore F1 atingindo consistentemente patamares superiores a 0.7 (70%), o que indica que, embora a sobreposição léxica exata (BLEU) seja baixa, o significado contextual das respostas é preservado entre os diferentes modelos. As métricas ROUGE-1 e ROUGE-L mantiveram-se estáveis em aproximadamente 0.5 e 0.25, respectivamente, sugerindo que a estrutura de unigramas é mais similar do que a sequência de n-gramas mais longos, independentemente do par de modelos comparado.

2.2.4 Desempenho nas questões abertas

A avaliação das questões dissertativas combinou duas abordagens: (i) aderência à rubrica oficial do exame, com scores normalizados, e (ii) avaliação qualitativa por modelo juiz (llama3.2:3b), que atribuiu notas de 0 a 5 para argumentação, precisão e coesão. A Tabela 7 apresenta os resultados consolidados.

Tabela 7: Desempenho consolidado nas questões abertas: rubrica e avaliação comparativa

Modelo	Rubrica (%)	Argum.	Precisão	Coesão	Score Final
llama3.2:3b	44,73	4,00	3,83	4,00	3,93
qwen2.5:3b	39,60	3,83	3,92	3,92	3,88
gemma2:2b	33,00	3,83	4,08	4,08	3,98

O **llama3.2:3b** obteve a melhor aderência à rubrica (44,73%), superando o qwen2.5:3b (39,60%) e o gemma2:2b (33,00%). Entretanto, na avaliação qualitativa, o **gemma2:2b** lidera com score final de 3,98, indicando respostas mais bem escritas apesar de menor alinhamento com os critérios formais da banca. Essa dissociação entre rubrica e qualidade textual — onde o modelo com pior aderência formal produz as respostas de melhor qualidade percebida.

A Figura 13 apresenta o desempenho dos modelos *Gemma 2:2b*, *Llama 3.2:3b* e *Qwen 2.5:3b* em questões abertas do Exame da OAB, segmentado por aproveitamento médio percentual via rubrica normalizada e por notas médias nos critérios de argumentação, precisão e coesão.




Figura 13: Comparação de desempenho em questões abertas: aproveitamento por rubrica normalizada e avaliação por critérios de argumentação, precisão e coesão.

Os dados indicam que o modelo *Llama 3.2:3b* obteve o maior aproveitamento médio na rubrica normalizada, aproximando-se de 45%, seguido pelo *Qwen 2.5:3b* (40%) e *Gemma*

2:2b (33%). Na avaliação qualitativa (escala 0-5), os modelos mantiveram uma performance equilibrada, com notas situadas na faixa de 3.8 a 4.1, destacando-se uma leve superioridade do Gemma 2:2b em precisão e coesão, enquanto o Llama 3.2:3b apresentou melhor desempenho em argumentação. Essa disparidade entre o aproveitamento percentual e a avaliação por critérios sugere que, embora os modelos mantenham a estrutura textual, a exatidão técnica jurídica ainda é um desafio para modelos de baixa escala de parâmetros.

Cabe ressaltar que o llama3.2:3b atua simultaneamente como modelo avaliado e como juiz, o que pode introduzir viés de auto-preferência. Essa limitação, comum em avaliações locais sem acesso a juízes externos, deve ser considerada na interpretação dos scores comparativos.

2.2.5 Síntese

A Tabela 8 consolida as principais métricas em uma visão geral.

Tabela 8: Classificação consolidada dos modelos

Modelo	Acur. MC	Rubrica	Score Juiz	BERTScore médio
qwen2.5:3b	50,41%	39,60%	3,88	0,754
llama3.2:3b	39,84%	44,73%	3,93	0,755
gemma2:2b	41,46%	33,00%	3,98	0,752

Assim como nos demais lotes da equipe, não há um vencedor absoluto: o **qwen2.5:3b** domina as questões objetivas, o **llama3.2:3b** tem maior aderência à rubrica nas questões abertas e o **gemma2:2b** produz as respostas de maior qualidade textual. A consistência desse padrão entre os lotes dos integrantes do grupo — cada um com subconjuntos distintos de questões — indica que essas tendências são propriedades intrínsecas dos modelos e não artefatos da amostragem.

O fato de os resultados terem sido obtidos em hardware sem GPU dedicada demonstra a viabilidade de execução de LLMs compactos em configurações modestas, ainda que com tempo de inferência mais elevado. A qualidade das respostas não foi comprometida pela limitação de hardware, apenas a velocidade de processamento.

2.3 Éricles dos Santos Cunha

Questões atribuídas: J1: 153–164 | J2: 1600–1722

A implementação completa do pipeline de dados e inferência — abrangendo as etapas de curadoria de questões da OAB, pré-processamento, execução de inferência via LLMs

e geração de métricas de avaliação — encontra-se disponível em repositório público no GitHub³. O repositório segue a abordagem *Docs-as-Code*, integrando documentação técnica e código-fonte sob controle de versão.

2.3.1 Escolha e justificativa dos modelos

Os experimentos de inferência foram conduzidos em ambiente local, sob o sistema operacional *Windows* 11. A infraestrutura computacional utilizada foi composta por um processador Intel Core i5 de 13^a geração, 32 GB de memória RAM e uma unidade de processamento gráfico NVIDIA GeForce RTX 3050, com 6,0 GB de memória dedicada (VRAM). A execução padronizada dos modelos foi realizada por meio da ferramenta Ollama, responsável pelo gerenciamento local das requisições e dos pesos das redes neurais, garantindo maior controle e reprodutibilidade dos experimentos.

Foram utilizados o **Llama 3.2 (3B)**, o **Gemma 2 (2B)** e o **Qwen 2.5 (3B)**. Esta escolha fundamentou-se na diversidade de arquitetura, possibilitando a comparação de diferentes metodologias de pré-treinamento e alinhamento em um mesmo domínio jurídico. Por fim, a localização linguística foi um critério determinante, visto que todos os modelos possuem suporte nativo ao idioma português, requisito mandatório para o processamento das questões do Exame da OAB, enquanto a disponibilidade no ecossistema Ollama assegurou a consistência do pipeline e a reprodutibilidade dos resultados.

2.3.2 Resultados das questões objetivas

A Tabela 9 apresenta as métricas de classificação obtidas pelos três modelos no conjunto de 123 questões de múltipla escolha. O **qwen2.5:3b** alcançou o melhor resultado em todos os indicadores, com acurácia de 50,41% e F1-Score de 0,4742, sendo o único modelo a ultrapassar a marca de 50% de acerto. O **llama3.2:3b** ficou em segundo lugar (46,34%), enquanto o **gemma2:2b** teve o menor aproveitamento (40,65%). Apesar de o qwen2.5:3b ter superado os demais, o desempenho geral dos três modelos permanece limitado, o que é esperado para LLMs com menos de 4 bilhões de parâmetros diante da complexidade das questões da OAB.

Tabela 9: Métricas de classificação dos modelos nas questões objetivas

Modelo	Acurácia	Precisão	Recall	F1
llama3.2:3b	0,4634	0,4096	0,3662	0,3632
gemma2:2b	0,4065	0,4124	0,3979	0,3884
qwen2.5:3b	0,5041	0,5250	0,4903	0,4742

³https://github.com/Ericles-Porty/Topicos_Avancados_2026_1_Equipe_JUD_3_atividade1

2.3.3 Consistência entre modelos nas questões abertas

Para avaliar o grau de concordância entre os modelos nas 12 questões dissertativas, foram calculadas métricas de similaridade textual e semântica entre cada par. A Tabela 10 apresenta os resultados.

Tabela 10: Métricas de similaridade entre pares de modelos nas questões abertas

Par de modelos	BLEU	ROUGE-1	ROUGE-2	ROUGE-L	BERTScore F1
llama3.2:3b vs gemma2:2b	0,1550	0,4997	0,2249	0,2651	0,7568
llama3.2:3b vs qwen2.5:3b	0,1288	0,4796	0,2081	0,2405	0,7534
gemma2:2b vs qwen2.5:3b	0,1145	0,5003	0,1855	0,2222	0,7502

Os três pares mantêm BERTScore F1 acima de 0,75, o que indica que, do ponto de vista semântico, os modelos transmitem ideias parecidas mesmo utilizando vocabulários distintos. As métricas lexicais confirmam essa diferença de forma: o BLEU fica entre 0,11 e 0,16 e o ROUGE-L não passa de 0,27, mostrando que a sobreposição literal de termos é baixa. Esse comportamento é natural em respostas jurídicas abertas, onde não existe uma formulação canônica esperada. O par llama3.2:3b–gemma2:2b apresenta os valores mais altos em quase todas as métricas, sugerindo que esses dois modelos produzem respostas mais próximas entre si do que em relação ao qwen2.5:3b.

2.3.4 Desempenho nas questões abertas

A avaliação das questões dissertativas foi feita de duas formas: (i) comparação automática com a rubrica oficial do exame, e (ii) avaliação qualitativa por um modelo juiz. A Tabela 11 detalha o aproveitamento normalizado de cada modelo por área do Direito.

Tabela 11: Aproveitamento nas questões abertas por área do Direito (% da rubrica)

Questão	llama3.2:3b	gemma2:2b	qwen2.5:3b
Dir. Trabalho – q3	0%	0%	0%
Dir. Trabalho – q4	0%	0%	0%
Dir. Constitucional – peça	100%	⁴	0%
Dir. Constitucional – q1	0%	0%	0%
Dir. Constitucional – q2	0%	0%	52%
Dir. Constitucional – q3	0%	0%	0%
Dir. Constitucional – q4	0%	0%	0%
Dir. Empresarial – peça	0%	100%	0%
Dir. Empresarial – q1	0%	0%	0%
Dir. Empresarial – q2	100%	100%	48%
Dir. Empresarial – q3	100%	36%	100%
Dir. Empresarial – q4	0%	0%	0%
Média	25,00%	21,45%	16,67%

O resultado mais evidente é que a área de Direito do Trabalho foi um ponto cego para todos os modelos: nenhum conseguiu atender sequer parcialmente os critérios da rubrica. Em contraste, Direito Empresarial foi a área de melhor desempenho, com destaque para a questão 2 (onde llama e gemma atingiram 100%) e a questão 3 (100% para llama e qwen). Na área de Direito Constitucional, o llama3.2:3b se destacou ao acertar integralmente a peça profissional, enquanto o qwen2.5:3b foi o único a obter pontuação parcial na questão 2 (52%). Nenhum modelo domina todas as questões, e os acertos de cada um se distribuem de forma complementar.

Apesar dos baixos percentuais de rubrica, a qualidade da escrita se mantém alta. A avaliação comparativa, feita por um modelo juiz (llama3.2:3b) que atribuiu notas de 0 a 5 para argumentação, precisão e coesão, mostra que o **gemma2:2b** lidera com nota final de 4,83, seguido pelo **qwen2.5:3b** (4,67) e pelo **llama3.2:3b** (3,97). O score final é calculado como $0,4 \times \text{argumentação} + 0,4 \times \text{precisão} + 0,2 \times \text{coesão}$. A Figura 18 ilustra essa dualidade entre rubrica e qualidade textual.

Os resultados obtidos nas questões de múltipla escolha, sintetizados na Figura 15, demonstram que o modelo **qwen2.5:3b** apresenta a maior eficácia global entre os modelos testados. Observa-se que o **qwen2.5:3b** supera consistentemente os demais em todas as métricas, sendo o único a ultrapassar a marca de 0,5 em Acurácia e *Precision*. O modelo llama3.2:3b posiciona-se como o segundo melhor em termos de Acurácia ($\approx 0,46$), embora sua *Precision* e *F1-Score* sejam comparáveis aos índices do **gemma2:2b**, que apresentou o

⁴O modelo gemma2:2b não produziu uma resposta válida para esta questão.

desempenho mais modesto no conjunto avaliado.




Figura 14: Métricas de avaliação exata na comparação entre modelos

Figura 15: Desempenho nas questões abertas: rubrica normalizada e avaliação comparativa

Cabe destacar uma limitação metodológica: o modelo llama3.2:3b atua simultaneamente como avaliado e como juiz, o que pode introduzir viés de auto-preferência nas notas. Diferente de abordagens que utilizam um juiz externo (como o GPT-4o-mini), a avaliação local com o próprio modelo avaliado deve ser interpretada com cautela.

2.3.5 Síntese e classificação final

A Tabela 12 consolida todas as métricas em uma visão geral. O ranking final depende do critério adotado: por acurácia em múltipla escolha, o qwen2.5:3b vence; por aderência à rubrica nas questões abertas, o llama3.2:3b é o melhor; e pela qualidade da escrita, o gemma2:2b se destaca.

Tabela 12: Classificação consolidada dos modelos

Modelo	Acur. MC	Rubrica Arg.	Prec.	Coesão	Score Final
gemma2:2b	40,65%	21,45%	4,83	4,83	4,83
llama3.2:3b	46,34%	25,00%	4,00	3,92	3,97
qwen2.5:3b	50,41%	16,67%	4,67	4,67	4,67

Essa ausência de um vencedor absoluto reforça que avaliações baseadas em uma única métrica podem ser enganosas. O gemma2:2b, por exemplo, ficou em último lugar na acurácia de múltipla escolha (40,65%), mas lidera com folga na qualidade de escrita (score final 4,83). Já o qwen2.5:3b tem a melhor taxa de acerto nas questões objetivas, porém obteve a menor média de rubrica nas questões abertas (16,67%). A Figura 16 apresenta um panorama visual que reúne essas diferentes dimensões de avaliação.




Figura 16: Panorama consolidado: rubricas, avaliação comparativa, métricas entre modelos e desempenho em múltipla escolha

Em comparação com os resultados obtidos por Reinan sobre um lote distinto de questões, nota-se uma inversão no ranking de múltipla escolha: no lote de Reinan, o gemma2:2b liderou com 43,44% de acurácia, enquanto neste lote ele ficou em último (40,65%). Essa variação entre subconjuntos diferentes da OAB evidencia a instabilidade do desempenho desses modelos compactos, reforçando que os resultados são sensíveis à composição específica das questões avaliadas.

A proximidade entre as métricas de *Precision*, *Recall* e *F1* para cada modelo individual sugere um equilíbrio na distribuição de acertos, sem viés acentuado para classes específicas. Contudo, o teto de desempenho próximo a 0,5 evidencia a complexidade do Exame da OAB para modelos de linguagem de pequeno porte executados localmente, indicando que, embora possuam capacidade de inferência, a interpretação de enunciados jurídicos densos ainda representa um desafio significativo para essas arquiteturas.

2.3.6 Resultados da avaliação cruzada

A avaliação das respostas para as 12 questões dissertativas seguiu uma metodologia distinta, visto que o lote selecionado não dispunha de gabaritos oficiais para confronto direto. Nessas circunstâncias, a análise fundamentou-se em métricas *cross-model*, conforme ilustrado na Figura 17, que mensuram o grau de convergência e similaridade entre as saídas geradas pelas diferentes arquiteturas (Llama 3.2, Gemma 2 e Qwen 2.5). Foram aplicados os índices BLEU e ROUGE (1 e L) para avaliar a sobreposição léxica, além do BERTScore F1 para aferir a equivalência semântica.




Figura 17: Comparação entre pares de modelos com métricas de similaridade

Os resultados demonstram uma elevada consistência semântica entre os pares de modelos, com o BERTScore F1 mantendo-se estavelmente no patamar de 0,75. Este comportamento indica que, embora as arquiteturas possuam processos de treinamento distintos, as respostas convergem para interpretações jurídicas semelhantes. Por outro lado, os índices de sobreposição de n-gramas apresentaram valores inferiores, com o BLEU situado em torno de 0,15 e o ROUGE-L próximo a 0,25. Essa discrepância entre os scores semânticos e léxicos evidencia que os modelos, apesar de concordarem quanto ao conteúdo e mérito das questões, utilizam estruturas sintáticas e vocabulários técnicos variados para a composição dos textos jurídicos.

2.3.7 Resultados da avaliação com modelo juiz

A análise do desempenho dos modelos nas questões abertas, apresentada na Figura 18, revela uma discrepância significativa entre a capacidade de aderência às rubricas oficiais e a qualidade intrínseca da escrita (argumentação, precisão e coesão). No gráfico de *Rubrica (normalizada)*, observa-se que o aproveitamento médio é reduzido para todos os modelos, com o llama3.2:3b atingindo o melhor desempenho relativo (aproximadamente 25%), seguido pelo gemma2:2b ($\approx 21\%$) e pelo qwen2.5:3b ($\approx 17\%$). Esses valores indicam uma dificuldade generalizada em contemplar os critérios específicos de pontuação exigidos pela banca examinadora. Em contrapartida, o gráfico de *Avaliação Comparativa (0-5)* demonstra que, sob a perspectiva qualitativa, os modelos mantêm um padrão elevado de escrita. O gemma2:2b lidera os indicadores de Argumentação, Precisão e Coesão, aproximando-se da nota máxima (5). O qwen2.5:3b apresenta desempenho consistente, ligeiramente superior ao llama3.2:3b, que obteve médias em torno de 4 em todos os quesitos.




Figura 18: Comparação de desempenho em questões abertas: aproveitamento por rubrica normalizada e avaliação por critérios de argumentação, precisão e coesão.

2.4 Victor Leonardo Mascarenhas Soares Horta

Questões atribuídas: J1: 201–210 | J2: 2092–2210

Toda a implementação do pipeline, desde a curadoria das questões até a geração dos gráficos de avaliação, está disponível no repositório público no GitHub⁵. A partir dele é possível acessar a documentação web e navegar pelos artefatos para visualizar os resultados obtidos.

2.4.1 Escolha e justificativa dos modelos

A seleção dos Modelos de Linguagem de Grande Escala (LLMs) para este experimento não se deu de forma arbitrária, mas fundamentou-se na necessidade de contrapor diferentes paradigmas arquitetônicos e estratégias de treinamento dentro das restrições de inferência local (hardware limitado a 8GB de VRAM). A literatura aponta que a avaliação em domínios altamente especializados, como o jurídico, exige modelos capazes não apenas de recuperação factual, mas de processamento lógico-dedutivo avançado (Zhao et al., 2025). Sob essa ótica, a tríade selecionada compõe um ecossistema metodologicamente robusto para análise:

Llama 3.1 8B (Adoção como Baseline do Estado da Arte) O modelo Llama 3.1, desenvolvido pela Meta, foi adotado como o padrão-ouro de controle (baseline). Sua justificativa repousa em sua arquitetura densa amplamente otimizada através de Reinforcement Learning from Human Feedback (RLHF) e Direct Preference Optimization (DPO). Segundo Dubey et al. (2024), a família Llama 3 maximiza a densidade de conhecimento por parâmetro, resultando em capacidades de instruction-following (obediência a instruções)

⁵https://github.com/Leonardomascarenhas91/Topicos_Avancados_2026_1_Equipe_JUD_3_atividade1

superiores na sua categoria de tamanho. No contexto do Exame da OAB, espera-se que sua vasta exposição a dados multilíngues e estruturas semânticas complexas durante o pré-treinamento garanta uma recuperação factual direta altamente precisa, servindo como o limite superior de desempenho para modelos generalistas densos.

Mistral 7B (Eficiência Arquitetônica e Gestão de Contexto) A inclusão do Mistral 7B (Mistral AI) visa avaliar o impacto de inovações de eficiência computacional na compreensão hermenêutica. Conforme descrito por Jiang et al. (2023), o Mistral 7B utiliza técnicas avançadas como Grouped-Query Attention (GQA) e Sliding Window Attention (SWA). Estas otimizações permitem que o modelo processe informações contextuais mais longas e complexas com menor custo computacional, frequentemente superando modelos com o dobro do seu tamanho em benchmarks analíticos. No domínio jurídico brasileiro, onde os enunciados tendem a ser prolixos e as alternativas apresentam nuances sintáticas sutis, a capacidade do Mistral de manter a coerência em contextos estendidos justifica sua relevância neste estudo.

DeepSeek-R1 8B (Especialização em Raciocínio via Destilação) A escolha do DeepSeek-R1 8B justifica-se pela sua arquitetura inerentemente focada no "pensamento" estruturado (reasoning-focused). Distinto dos modelos generalistas tradicionais, a série R1 emprega técnicas de aprendizado por reforço para incentivar o comportamento de Chain-of-Thought (Cadeia de Pensamento) nativo (DeepSeek-AI, 2025). Na prática, isto simula o raciocínio humano de "Sistema 2" (analítico e deliberativo). Como a classificação metodológica deste projeto abrange níveis de "Raciocínio Lógico-Dedutivo" e "Hermenêutica Jurídica Complexa", postula-se que a capacidade do DeepSeek-R1 de destilar lógicas intermediárias antes de gerar a resposta final oferecerá uma vantagem competitiva significativa frente a questões que demandam a subsunção de fatos à norma (aplicação do caso concreto à lei).

2.4.2 Resultados da avaliação exata

A Tabela 1 apresenta o desempenho dos três modelos nas 122 questões objetivas do lote atribuído, avaliados por meio de Acurácia, Precisão, Recall e F1-Score. O **gemma2:2b** obteve a maior acurácia (0,4344), seguido pelo **qwen2.5:3b** (0,4180) e **llama3.2:3b** (0,3607). Nenhum modelo ultrapassou 50%, resultado esperado considerando o tamanho reduzido dos modelos e a complexidade inerente às questões da OAB.

2.4.3 Resultados das Questões Objetivas (J2)

Os resultados obtidos no dataset J2, composto por 120 questões extraídas do OAB Bench, consolidam o desempenho quantitativo dos modelos testados. A avaliação utilizou métricas de classificação clássica para mensurar a precisão e a capacidade de recuperação de informações jurídicas. A Figura 19 apresenta uma comparação visual do desempenho dos

modelos Llama 3.1 8B, Mistral 7B e DeepSeek-R1 8B em termos de acurácia geral nas questões de múltipla escolha.




Figura 19: Comparação de Acurácia dos Modelos no OAB Bench (J2)

Tabela 13: Métricas de Desempenho - Dataset J2 (Múltipla Escolha)

Modelo	Acurácia (%)	Precision	Recall	F1 (macro)
Llama 3.1 8B	46.79	0.47	0.47	0.43
Mistral 7B	45.87	0.46	0.46	0.40
DeepSeek-R1 8B	48.62	0.49	0.49	0.50

**Nota: Os valores detalhados da tabela serão integrados após a consolidação final dos dados de inferência.*

2.4.4 Desempenho nas Questões Abertas (J1)

Para o dataset J1, a avaliação focou na qualidade da geração de texto jurídico. Foram aplicadas métricas de processamento de linguagem natural (NLP) para comparar as respostas geradas com o padrão esperado (Ground Truth). Os resultados demonstram que o modelo DeepSeek-R1 8B obteve uma ligeira vantagem no BERTScore, sugerindo maior proximidade semântica com as fundamentações legais esperadas.

Tabela 14: Métricas de NLP - Dataset J1 (Questões Abertas)

Modelo	BLEU	ROUGE-1	ROUGE-2	ROUGE-L	BERTScore_F1
Llama 3.1 8B	0.0	0.0	0.0	0.0	0.4684
Mistral 7B	0.0	0.0	0.0	0.0	0.4668
DeepSeek-R1 8B	0.0	0.0002	0.0	0.0002	0.4746

2.4.5 Consistência entre Modelos nas Questões Abertas

A análise de consistência revelou que, embora as métricas de sobreposição de n-gramas (BLEU/ROUGE) tenham sido baixas devido à natureza expansiva e técnica das respostas jurídicas, a consistência semântica capturada pelo BERTScore manteve-se estável acima de 0.46 para todos os modelos. Isso indica que, apesar de utilizarem vocabulários distintos, os modelos convergem para interpretações jurídicas similares nos subdomínios analisados (Direito Civil, Penal e Tributário).

2.4.6 Síntese e Classificação Final

A síntese dos experimentos aponta o DeepSeek-R1 8B como o modelo de maior eficácia analítica para o contexto deste projeto, seguido de perto pelo Llama 3.1 8B. A infraestrutura baseada em Ollama permitiu uma inferência estável no hardware RTX 2000, garantindo que a latência de processamento não comprometesse a integridade dos dados coletados para o Grupo 3. A classificação final leva em consideração o equilíbrio entre desempenho quantitativo (J2) e qualitativo (J1).

2.4.7 Resultados da Avaliação Cruzada

A avaliação cruzada foi estruturada para mitigar vieses de modelo único. Através da comparação das saídas analíticas, observou-se que o DeepSeek-R1 tende a fornecer conclusões mais estruturadas, enquanto o Mistral 7B apresenta uma síntese mais objetiva. Essa dispersão de resultados foi consolidada graficamente no radar de desempenho apresentado na Figura 20, que visualiza de forma clara os pontos fortes e fracos de cada modelo nos critérios de avaliação definidos.




Figura 20: Métricas de Desempenho (J2)

3 Referências

1. Zhao, H. et al. *LLM Evaluation: A Comprehensive Survey*. arXiv, 2025. Disponível em: <https://arxiv.org/html/2504.21202v1>.
2. Maritaca AI. *OAB Bench*. Disponível em: <https://github.com/maritaca-ai/oab-bench>.
3. Garcia, E. *OAB Exams*. Disponível em: https://huggingface.co/datasets/eduagarcia/oab_exams.
4. Ollama. *Ollama — Run LLMs locally*. Disponível em: <https://ollama.com/>.
5. Typer. *Typer — library for building CLIs in Python*. Disponível em: <https://typer.tiangolo.com/>.
6. Astral. *uv — Python package manager*. Disponível em: <https://docs.astral.sh/uv/>.